




Computing Information Gain with Apache Hadoop Map/Reduce

واحد درسی: تحلیل کلان داده ها

رشته تحصیلی: علم و مهندسی کامپیوتر

استاد: دکتر فرساد زمانی بروجنی

دانشجو: محمد احمدزاده (۴۰۴۰۱۱۹۳۵)

بهار ۱۴۰۵

فهرست

۳	۱-مقدمه
۳	۲-روش حل
۷	۳-نیازمندی ها
۷	۳-۱- مجموعه داده ها
۸	۳-۲- محیط پیاده سازی
۹	۴- پیاده سازی
۱۰	۴-۱- پیش پردازش داده ها
۱۳	۵-کامپایل برنامه نگاشت کاهش نوشته شده در زبان جاوا
۱۵	۶- اجرای سناریو با ۱۲ آزمایش
۱۷	۷- تحلیل نتایج
۱۸	۸- نتیجه گیری
۲۰	۹- منابع
*	۱۰-پیوست شماره ۱: فرآیند راه اندازی Apache Hadoop بر روی Ubuntu ۲۴.۰۴ LTS
*	۱۰- پیوست شماره ۲: کدهای پیش پردازش داده ها به زبان پایتون
*	۱۰- پیوست شماره ۲: کدهای اجرای سناریو Apache Hadoop و اجرای Classifier

GitHub Repository Link

۱-مقدمه

حجم کلان داده‌های امروزی نیاز به روش‌های هوشمند برای کاهش ابعاد دارد. انتخاب ویژگی یکی از حیاتی‌ترین مراحل در تحلیل کلان داده‌ها است. این فرایند باعث بهبود سرعت مدل و کاهش پیچیدگی محاسباتی می‌شود. در این گزارش ما از چارچوب MapReduce برای محاسبه معیار Information Gain استفاده می‌کنیم. این معیار نشان می‌دهد هر ویژگی چقدر برای پیش‌بینی Label ها مفید است. مجموعه داده انتخابی ما EMBER است که یک منبع استاندارد برای تحلیل بدافزارها محسوب می‌شود (Anderson & Roth, ۲۰۱۸).

پردازش موازی با MapReduce امکان تحلیل کلان داده‌ها را فراهم می‌کند. روش سنتی محاسبه Information Gain برای داده‌های ترابایتی غیرممکن است. روش پیشنهادی داده را بین چندین Mapper تقسیم می‌کند. هر Mapper تنها روی یک بخش از داده کار می‌کند. سپس Reducer ها نتایج محلی را برای محاسبه امتیاز نهایی ترکیب می‌کنند. این روش مقیاس‌پذیر است و روی خوشه‌های کامپیوتری به خوبی اجرا می‌شود (Ghemawat & Dean, 2008).

هدف اصلی این گزارش محاسبه امتیاز نهایی برای هر ویژگی است. در پایان یکصد ویژگی برتر را انتخاب کرده و عملکرد یک طبقه‌بند را ارزیابی می‌کنیم. این ارزیابی بر اساس معیارهایی مانند دقت و زمان اجرا انجام می‌شود. در این گزارش ابتدا معماری کلی راهکار توضیح داده می‌شود. سپس جزئیات پیاده‌سازی با جاوا روی پلتفرم Apache Hadoop ارائه می‌گردد. در بخش نتایج جداول زمان اجرا و دقت مدل گزارش خواهد شد. در نهایت نقاط قوت و ضعف روش بررسی می‌شود.

۲-روش حل

در این پروژه، ما موفق به پیاده‌سازی یک سیستم کامل انتخاب ویژگی مبتنی بر الگوریتم MapReduce برای دیتاست EMBER شدیم. هدف اصلی، محاسبه معیار Information Gain برای ویژگی‌های عددی موجود در مجموعه داده و سپس انتخاب ۱۰۰ ویژگی برتر جهت انجام طبقه‌بندی بود. تمام مراحل پروژه شامل پیش‌پردازش داده، پیاده‌سازی توابع نگاشت کاهش در محیط Hadoop نسخه ۳.۳.۵ و در نهایت ارزیابی صحت طبقه‌بندی انجام شد. در این گزارش، جزئیات فنی هر مرحله به صورت دقیق و منظم ارائه می‌شود.

مرحله اول: پیش پردازش داده و بارگذاری در HDFS

پیش از هر اقدامی، ما داده‌های خام مجموعه داده EMBER را که به صورت فایل JSONL با ساختاری تو در تو ذخیره شده بودند، مورد بررسی و تحلیل قرار دادیم. بررسی اولیه نشان داد که هر رکورد شامل ۶۸۱ ویژگی عددی است که پیشتر فرآیند Vectorization روی آنها انجام شده بود. این ویژگی‌ها شامل بخش‌های مختلفی مانند هیستوگرام بایت‌ها، آنتروپی بایت‌ها، ویژگی‌های رشته‌ای عددی شده، و ویژگی‌های ساختاری فایل بودند. نکته حائز اهمیت این بود که تمام مقادیر غیر عددی مانند Hash ها، تاریخ‌ها و رشته‌های متنی قبلاً در مرحله Vectorization به اعداد تبدیل شده بودند.

پس از اطمینان از یکسان بودن تعداد ویژگی‌ها در تمام رکوردها، ما داده‌ها را از فرمت JSONL به فرمت CSV ساده تبدیل کردیم. در این تبدیل، هر خط از فایل خروجی شامل برچسب (صفر برای غیر مخرب و یک برای مخرب) و به دنبال آن ۶۸۶ مقدار عددی جدا شده با کاما بود. این فرمت ساده، پردازش خط به خط در Mapper ها را بسیار کارآمد می‌ساخت. ما همچنین مقادیر Null و بی‌نهایت را با صفر جایگزین کردیم تا از بروز خطا در محاسبات ریاضی جلوگیری شود. در نهایت، برای اطمینان از توازن داده‌ها در مرحله آموزش و ارزیابی، ۵۰۰۰ رکورد متوازن شامل ۲۵۰۰ نمونه از هر کلاس استخراج و در فایلی جداگانه ذخیره شد.

بارگذاری داده‌ها در سیستم فایل توزیع شده HDFS گام بعدی بود. فایل CSV حاوی ۵۰۰۰ رکورد به دایرکتوری /user/hadoop/input در HDFS منتقل شد. سیستم Hadoop به طور خودکار این فایل را بر اساس اندازه بلوک پیش فرض که ۱۲۸ مگابایت بود، به چندین بلوک تقسیم کرد. از آنجایی که حجم فایل ما کمتر از ۱۲۸ مگابایت بود، فایل در یک بلوک ذخیره شد، اما در زمان اجرای Job، Hadoop به لطف InputFormat مناسب، قادر به تقسیم منطقی داده‌ها بین Mapper های مختلف بود. ما از TextInputFormat استفاده کردیم که هر خط از فایل را به عنوان یک رکورد جداگانه با کلیدی از نوع موقعیت بایت و مقداری از نوع متن در اختیار می‌رها قرار می‌داد.

مرحله دوم: پیاده‌سازی محاسبه Information Gain در مدل MapReduce

در این مرحله، ما کلاس اصلی Driver MapReduce را طراحی و پیاده‌سازی کردیم. این کلاس مسئول تنظیم پارامترهای مختلف Job، معرفی کلاس‌های Mapper/Reducer، و تعیین انواع داده‌های ورودی و خروجی بود. ما در این کلاس قابلیت دریافت پارامترهای متغیر مانند تعداد Mappers و تعداد Reducers را از طریق خط فرمان فراهم آوردیم تا بتوانیم آزمایش‌های مختلف جدول خواسته شده را اجرا کنیم. همچنین، با

استفاده از متد `ToolRunner` و کلاس `GenericOptionsParser`، امکان استفاده از پارامترهای استاندارد Hadoop مانند `D mapreduce.job.maps` را فراهم کردیم. تنظیم اندازه هر `chunk` نیز از طریق پارامتر `mapreduce.input.fileinputformat.split.maxsize` انجام می‌شد که مستقیماً بر تعداد مپ‌های مؤثر تأثیر می‌گذاشت.

طراحی Mapper این Job مهمترین بخش پروژه بود، زیرا محاسبه `Information Gain` برای هر ویژگی نیازمند دسترسی به تمام داده‌های موجود در آن `chunk` بود. برای حل این مسئله، ما از الگوی `Stateful Mapper` استفاده کردیم. در متد `setup` که قبل از پردازش هر `chunk` فراخوانی می‌شود، چندین آرایه از نوع `ArrayList` برای ذخیره موقت برچسب‌ها و مقادیر ویژگی‌ها ایجاد کردیم. سپس در متد `map`، هر رکورد ورودی را تجزیه کرده، برچسب و مقدار ویژگی آن را استخراج و در آرایه‌های مربوطه ذخیره می‌کردیم. پس از خواندن تمام رکوردهای آن `chunk`، متد `cleanup` فراخوانی می‌شد و در این متد بود که محاسبات اصلی صورت می‌گرفت. برای هر ویژگی از ۰ تا ۶۸۵، ابتدا آنتروپی کل برچسب‌ها را محاسبه می‌کردیم. سپس برای محاسبه آنتروپی شرطی، مقادیر پیوسته آن ویژگی را به ۱۰ دسته مساوی تقسیم کرده و برای هر دسته، آنتروپی برچسب‌های موجود در آن دسته را محاسبه و به صورت وزنی جمع می‌زدیم. در نهایت `Information Gain` آن ویژگی از تفاضل آنتروپی کل و آنتروپی شرطی به دست می‌آمد. خروجی Mapper به صورت کلید `feature_id` و مقداری شامل دو بخش `Information Gain` و تعداد نمونه‌های پردازش شده بود.

Reducer این Job مسئولیت تجمیع امتیازات محلی تولید شده توسط `Mappers` های مختلف را بر عهده داشت. Reducer ها کلیدهای دریافتی را که همان شناسه ویژگی بودند به ترتیب صعودی دریافت می‌کردند. برای هر ویژگی، ما دو متغیر جمع‌کننده تعریف کردیم: یکی برای مجموع وزنی `Information Gain` و دیگری برای مجموع تعداد نمونه‌ها. از آنجا که هر Mapper امتیاز محلی خود را به صورت ضرب `Information Gain` در تعداد نمونه‌های آن `chunk` ارسال می‌کرد، ما می‌توانستیم به سادگی این مقادیر را جمع بزنیم. در پایان پردازش یک ویژگی، امتیاز نهایی از تقسیم مجموع وزنی بر مجموع نمونه‌ها محاسبه می‌شد. این روش تجمیع وزنی اطمینان می‌داد که `chunk` های بزرگتر تأثیر بیشتری در امتیاز نهایی داشته باشند. در پایان، Reducer همه ویژگی‌ها را بر اساس امتیاز نهایی به صورت نزولی مرتب کرده و خروجی نهایی را تولید می‌کرد. این خروجی شامل شناسه هر ویژگی و امتیاز `Information Gain` محاسبه شده بود و مستقیماً برای انتخاب ۱۰۰ ویژگی برتر قابل استفاده بود.

مرحله سوم: اجرا، مانیتورینگ و جمع آوری نتایج

پس از تکمیل کدنویسی، کلاس‌های جاوا را با استفاده از خط فرمان کامپایل کرده و یک فایل JAR قابل اجرا ایجاد نمودیم. فرآیند ساختن JAR شامل تمام کلاس‌های کامپایل شده و یک فایل منیفست بود که کلاس اصلی درایور را معرفی می‌کرد. در این مرحله، ما ۱۲ آزمایش مختلف مطابق با جدول خواسته شده در صورت مسئله طراحی کردیم. این آزمایش‌ها شامل ترکیب‌های متفاوتی از تعداد Mappers، تعداد Reducers و اندازه chunk بودند. برای هر آزمایش، ما Job را با پارامترهای مربوطه اجرا کرده و زمان اجرای کل را با استفاده از اختلاف زمان شروع و پایان در درایور اصلی اندازه‌گیری می‌کردیم. همچنین برای اطمینان از تکرارپذیری نتایج، از یک مقدار تصادفی ثابت در فرآیند تقسیم داده‌ها استفاده کردیم.

در حین اجرای هر Job، ما به طور مداوم وضعیت اجرا را از طریق رابط کاربری وب ResourceManager که به طور پیش‌فرض روی پورت ۸۰۸۸ در دسترس بود، پایش می‌کردیم. این رابط کاربری اطلاعات ارزشمندی مانند تعداد تسک‌های تکمیل شده، میزان پیشرفت هر تسک، لاگ‌های خطا و هشدار، و میزان استفاده از حافظه و پردازنده را نمایش می‌داد. همچنین از خط فرمان نیز با استفاده از دستور `mapred job -status` قادر به دریافت گزارش خلاصه از وضعیت Job بودیم. در مواردی که Job با خطا مواجه می‌شد، خروجی خطاهای استاندارد و خروجی معمولی هر تسک از طریق دستور `yarn logs -applicationId` قابل دسترسی بود که عیب‌یابی را بسیار ساده می‌کرد. یکی از چالش‌های اصلی در این مرحله، مدیریت حافظه Mappers بود، زیرا ذخیره ۱۰۰۰ رکورد با ۶۸۶ ویژگی در حافظه نیازمند حدود ۵۰۰ مگابایت حافظه بود که با تنظیم پارامتر `mapreduce.map.memory.mb` آن را به مقدار مناسب افزایش دادیم.

پس از اتمام هر Job، خروجی نهایی شامل چندین فایل با نام‌های `part-r-00000` و مشابه آن در دایرکتوری مشخص شده در HDFS ذخیره می‌شد. ما با استفاده از دستور `hdfs dfs -cat` این فایل‌ها را خوانده و به صورت محلی ذخیره کردیم. خروجی هر فایل شامل خطوطی با فرمت «`feature_id, score`» بود که به صورت نزولی مرتب شده بودند. از آنجایی که هدف ما انتخاب ۱۰۰ ویژگی برتر بود، ما تنها ۱۰۰ خط اول این فایل را استخراج می‌کردیم. این ویژگی‌های انتخاب شده به همراه برچسب‌های متناظرشان، یک مجموعه داده جدید با ابعاد ۵۰۰۰ در ۱۰۰ تشکیل می‌دادند که آماده مرحله طبقه‌بندی بود.

برای ارزیابی صحت طبقه‌بندی، این مجموعه داده جدید را از HDFS دانلود کرده و در محیط محلی با استفاده از کتابخانه `scikit-learn` پایتون پردازش کردیم. ما داده‌ها را به دو بخش آموزش (۷۰ درصد) و تست (۳۰ درصد)

تقسیم کرده و روی چند طبقه بند داده‌های Train را آموزش دادیم. سپس مدل های آموزش دیده را روی داده‌های Test ارزیابی کرده و معیارهای صحت، دقت، فراخوانی و نمره F1 را محاسبه کردیم. این فرآیند را برای هر ۱۲ ترکیب پارامتر تکرار کرده و جدول نهایی نتایج را تولید کردیم.

۳-نیازمندی ها

۳-۱- مجموعه داده

مجموعه داده ^۱EMBER 2018 دومین نسخه از این مجموعه داده‌های معروف است که برای آموزش مدل‌های یادگیری ماشین در زمینه شناسایی بدافزارهای ویندوزی فایل‌های PE^۲ طراحی شده است. این نسخه که در سال ۲۰۱۸ منتشر شد. شامل ویژگی‌های استخراج‌شده از ۱ میلیون رکورد فایل PE و ۲۳۵۱ ویژگی است که در آن سال یا قبل از آن اسکن شده‌اند.

ویژگی‌ها و ساختار:

- محتوای مجموعه داده: این مجموعه شامل خود فایل‌های اجرایی اصلی نیست. بلکه شامل ویژگی‌های^۳ استخراج‌شده از این فایل‌ها را در قالب فایل‌های JSON^۴ است. این کار به کاهش حجم مجموعه داده کمک می‌کند و خطرات امنیتی کار با بدافزارهای واقعی را از بین می‌برد.
- انواع ویژگی‌ها: ویژگی‌های استخراج‌شده شامل اطلاعات سرآیند فایل^۵، توابع واردشده^۶، رشته‌های متنی، هیستوگرام بایت‌ها و میزان آنتروپی^۷ است که مجموعاً ۲۳۸۱ ویژگی را تشکیل می‌دهند.
- نسخه ویژگی: ویژگی‌های این مجموعه داده با نسخه ۲ نرم‌افزار LIEF استخراج شده‌اند. این دیتاست شامل برچسب‌های دقیق برای خانواده‌های مختلف بدافزار مانند Trojan, Virus, Worm, Backdoor, Spyware, Adware, Rootkit, Ransomware است که آن را برای وظایف طبقه‌بندی چندکلاسه^۸ مناسب می‌سازد.

^۱ Endgame Malware Benchmark for Empowering Researchers

^۲ Portable Executable

^۳ Features

^۴ JavaScript Object Notation

^۵ Header

^۶ Imports

^۷ Entropy

^۸ Multi-Class Classification

به طور خلاصه، یک مجموعه داده استاندارد و ارزشمند، به‌ویژه برای ارزیابی استحکام مدل‌های شناسایی بدافزار در برابر نمونه‌های پیچیده‌تر و جدیدتر است. (Ember Repository, 2018)

قابل ذکر است، برای استخراج بخشی از مجموعه داده که به آن نیاز داریم از کتابخانه `ijson` که یک تجزیه‌گر جریانی^۹ برای فایل‌های `JSON` در زبان `Python` است استفاده می‌کنیم. این کتابخانه بجای بارگذاری کل فایل در حافظه، عناصر را یکی‌یکی و به ترتیب می‌خواند. این ویژگی آن را برای کار با فایل‌های `JSON` بسیار بزرگ که در حافظه `RAM` جا نمی‌شوند ایده‌آل می‌کند. برخلاف کتابخانه استاندارد `json` که کل محتوا را به صورت یک شیء در حافظه بارگذاری می‌کند، `ijson` رویکرد مبتنی بر رویداد^{۱۰} با استفاده از `Iterator` ارائه می‌دهد و فقط بخش‌های مورد نیاز از ساختار فایل را پردازش می‌کند، بدون اینکه نیازی به تجزیه کامل فایل داشته باشید.

منبع پرونده مجموعه داده:

https://ember.elastic.co/ember_dataset_2018_2.tar.bz2

۳-۲- محیط پیاده سازی

تمام مراحل پیاده‌سازی در یک محیط مجازی انجام شده است. این محیط توسط نرم‌افزار `Virtual Box` نسخه ۷.۰ ایجاد گردید. و شبیه‌سازی از یک ماشین مجازی با مشخصات مشخص استفاده شد:

- سیستم عامل مهمان `Ubuntu 24.04 Lts` است. این نسخه یک توزیع پایدار محسوب می‌شود. هسته لینوکس در این نسخه بهینه‌سازی‌های خوبی برای ماشین‌های مجازی دارد. همچنین `Java Version 11` به عنوان ماشین مجازی اصلی انتخاب گردید `Hadoop`. نسخه ۳.۳.۵ کاملاً با این نسخه از `Java` سازگار است (Apache Hadoop, 2023).
- منابع سخت‌افزاری تخصیص داده شده به صورت دقیق کنترل شدند. میزان `RAM` معادل ۴ گیگابایت در نظر گرفته شد. این مقدار حافظه برای اجرای `NameNode` و `DataNode` در حالت `Pseudo Distributed` کافی است.

^۹ Streaming Parser

^{۱۰} Event-driven

- پردازنده مجازی شامل دو هسته با فرکانس ۲.۴ گیگاهرتز می‌باشد. این پردازنده توانایی اجرای همزمان Task Mapper ها را فراهم می‌کند.


نصب Apache Hadoop روی این ماشین در حالت Pseudo Distributed انجام پذیرفت. تمامی سرویس‌های HDFS و Yarn روی یک گره اجرا می‌شوند. این انتخاب به دلیل محدودیت حافظه ۴ گیگابایتی بسیار منطقی است. مسیر داده ورودی یعنی دیتاست EMBER در پوشه HDFS ذخیره شده است. خروجی نهایی برنامه نیز پس از اجرا به همان مسیر نوشته می‌شود. این پیکربندی امکان شبیه‌سازی یک خوشه واقعی را با کمترین منابع فراهم می‌کند. محیط شبیه‌سازی بصورت خلاصه در جدول ۱ نشان داده شده است.

جدول (۱): مشخصات محیط شبیه‌سازی

N	مولفه	مشخصات دقیق
۱	نرم‌افزار مجازی ساز	Virtual Box Version 7.0
۲	سیستم عامل مهمان	Ubuntu 24.04 Lts
۳	ماشین مجازی جاوا	Java Version 11
۴	پلتفرم پردازش داده	Apache Hadoop Version 3.3.5
۵	حافظه دسترسی تصادفی	۴ Gigabytes
۶	پردازنده مرکزی	Two Cores With 2.4 Gigahertz Frequency
۷	حالت اجرای Apache Hadoop	Pseudo Distributed Mode

۴- پیاده‌سازی

فرآیند Feature Selection در Apache Hadoop 3.3.5 براساس مراحل شکل ۵ انجام شده است.



شکل (۵): فرآیند Feature Selection در Apache Hadoop 3.3.5

۴-۱ پیش پردازش داده ها

- محتوای فایل مجموعه داده **EMBER-2018** در تصویر ۱ نشان داده شده است.

Name	Size	Packed	Type	Modified
..			File folder	
ember_model_2018.txt	127,284,141	?	Text Document	07/30/2019 1:2...
test_features.jsonl	1,869,447,2...	?	JSONL File	07/11/2019 1:1...
train_features_0.jsonl	566,173,907	?	JSONL File	07/11/2019 1:0...
train_features_1.jsonl	1,659,892,9...	?	JSONL File	07/11/2019 2:2...
train_features_2.jsonl	1,299,496,0...	?	JSONL File	07/11/2019 2:2...
train_features_3.jsonl	1,376,529,6...	?	JSONL File	07/11/2019 2:1...
train_features_4.jsonl	1,322,709,8...	?	JSONL File	07/11/2019 2:1...
train_features_5.jsonl	1,851,893,1...	?	JSONL File	07/11/2019 2:2...

شکل (۱): محتوای فایل فشرده مجموعه داده EMBER-2018

- نتیجه اجرای کد برای استخراج نمونه داده مورد نیاز از مجموعه داده ها

تعداد ۵۰۰۰ رکورد از مجموعه داده انتخاب شده است. ۲۵۰۰ عدد با Label=0 و ۲۵۰۰ عدد دیگر با Label=1 هستند. قابل ذکر است فرآیند Vectorization تمام داده‌های غیر عددی را به داده‌های عددی تبدیل می‌کند:

۱. Feature Hashing: رشته‌های imports و exports با هشینگ به بردارهای اسپارس تبدیل می‌شوند

۲. One-Hot Encoding: مقادیر categorical مانند subsystem و machine

۳. Count Encoding: آرایه‌های characteristics به تعداد اعضا تبدیل می‌شوند

۴. حذف فیلدهای غیر ضروری sha256, md5, appeared, avclass: در نسخه vectorized وجود ندارند.

پردازش داده‌ها در دو گام اصلی اجرا شده است. نخست، از فایل test_features.jsonl تعداد ۵۰۰۰ نمونه با توزیع کاملاً متوازن، ۲۵۰۰ نمونه از کلاس ۰ و ۲۵۰۰ نمونه از کلاس ۱ استخراج و در فایل میانی ذخیره می‌شود. بررسی فایل متوازن نشان داد که هر نمونه دارای بردار ویژگی به طول ۵۱۲ است و تمام

مؤلفه‌های اولین رکورد غیرصفر می‌باشند؛ این امر نشان از تراکم کامل داده‌ها و نبود ویژگی‌های صفر در نمونه‌هاست.

در گام دوم، عملیات نرمال‌سازی ویژگی‌ها با موفقیت بر روی تمام ۵۰۰۰ نمونه اعمال شد. در نتیجه، مجموعه داده، متوازن و نرمال‌سازی شده حاصل گردید که در قالب فایل CSV با حجم ۴۵.۰۴ مگابایت و با نام `normalized_dataset.csv` ذخیره شد. این مجموعه داده، به دلیل دارا بودن توزیع متوازن طبقات، ابعاد ثابت ویژگی‌ها، و نرمال‌بودن مقادیر، از آمادگی کامل برای به‌کارگیری در الگوریتم‌های یادگیری ماشین به‌ویژه در مسائل طبقه‌بندی دودویی برخوردار است. تصویر خروجی این مرحله در شکل ۲ و ۳ نشان داده شده است.

```
=====
DATA PROCESSING PIPELINE
=====
Reading from test_features.jsonl...
Reached target at row

Summary:
  Class 0: 2500 samples
  Class 1: 2500 samples

Saving 5000 records to balanced_5000_samples.jsonl...

Extraction completed!
  Total: 5000 records
  Class 0: 2500
  Class 1: 2500
  Output: balanced_5000_samples.jsonl

Reading balanced_5000_samples.jsonl...
Feature vector length: 512
  Processed 1000 lines, collected 1000 records
  Processed 2000 lines, collected 2000 records
  Processed 3000 lines, collected 3000 records
  Processed 4000 lines, collected 4000 records
  Processed 5000 lines, collected 5000 records

Data collection complete:
  Valid records: 5000
  Feature length: 512
  Class 0: 2500
  Class 1: 2500
  Non-zero features in first record: 512/512

Normalizing features...
Normalization complete

CSV saved to: normalized_dataset.csv
File size: 45.04 MB
```

شکل (۲): خروجی برنامه برای استخراج ۵۰۰۰ رکورد از مجموعه داده های EMBER-2018

```

=====
SAMPLE OF FIRST 3 RECORDS (first 10 features):
=====
feature_0000 feature_0001 feature_0002 feature_0003 ... feature_0007 feature_0008 feature_0009 label
0 0.033743 0.002971 0.001131 0.004968 ... 0.007297 0.001172 0.005257 0
1 0.001819 0.002619 0.000341 0.001876 ... 0.002340 0.002595 0.001358 0
2 0.004260 0.009943 0.003936 0.018052 ... 0.032073 0.006656 0.035403 1

[3 rows x 11 columns]

=====
PIPELINE COMPLETED
=====

Output file: normalized_dataset.csv
Total records: 5000
Total features: 512
Label column: 'label'

Final verification:
Records: 5000
Class 0: 2500
Class 1: 2500
PS G:\EmberJ\Me>

```

شکل (۳): خروجی برنامه برای استخراج ۵۰۰۰ رکورد از مجموعه داده های EMBER-2018

شکل ۴ نمایش جدولی بخش از فایل csv تولید شده برای پردازش در سکوی Apache Hadoop 3.3.5 را نشان می دهد.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
1	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00	feature_00
2	0.03374	0.00297	0.00113	0.00497	0.00157	0.00266	0.00565	0.0073	0.00117	0.00526	0.00522	0.0037	0.00174	0.00337	0.0037	0.00084	0.00123	0.00242	0.0036	0.00364
3	0.00182	0.00262	0.00034	0.00188	0.00186	0.00126	0.00254	0.00234	0.00259	0.00136	0.00113	0.00145	0.00234	0.00174	0.00106	0.00057	0.00137	0.00048	0.0005	0.00063
4	0.00426	0.00994	0.00394	0.01805	0.00761	0.01217	0.02131	0.03207	0.00666	0.0354	0.02384	0.0266	0.01093	0.01753	0.02573	0.00473	0.00964	0.01355	0.0311	0.02502
5	0.01774	0.0132	0.00427	0.01748	0.01805	0.00535	0.02042	0.0102	0.02429	0.02126	0.01822	0.01399	0.0249	0.01338	0.01156	0.00482	0.04911	0.01478	0.07664	0.01252
6	0.00539	0.00413	0.00086	0.00631	0.00355	0.00243	0.00437	0.00455	0.00444	0.00309	0.00337	0.00305	0.00523	0.00542	0.00212	0.00139	0.00396	0.00178	0.00218	0.0017
7	0.00478	0.00371	0.00104	0.00544	0.00215	0.00419	0.01372	0.00967	0.00213	0.00937	0.01038	0.00949	0.00352	0.00909	0.00948	0.00168	0.00307	0.00517	0.0098	0.00948
8	0.00104	0.00039	0.00013	0.00057	0.00018	0.00068	0.00028	0.00066	0.00029	0.00054	0.00064	0.00041	0.00019	0.00083	0.00028	0.00059	0.0003	0.00013	0.00026	0.00017
9	0.00312	0.0264	0.01272	0.06389	0.02686	0.04918	0.10203	0.11816	0.02662	0.12562	0.13016	0.11766	0.04434	0.11001	0.12047	0.02062	0.03848	0.12299	0.12727	0.11975
10	0.01603	0.00222	0.00167	0.00377	0.00287	0.00238	0.00588	0.00777	0.00212	0.00419	0.01396	0.00462	0.00219	0.0053	0.00426	0.00099	0.00264	0.00287	0.00538	0.00576
11	0.00244	0.00458	0.00096	0.00153	0.00056	0.0018	0.00215	0.00405	0.00097	0.00285	0.00252	0.00182	0.00065	0.00334	0.0012	0.00136	0.00209	0.00087	0.00146	0.00084
12	0.01597	0.00102	0.00046	0.00499	0.00097	0.00386	0.00303	0.00406	0.00083	0.00421	0.0034	0.00338	0.00349	0.00286	0.00344	0.00066	0.00121	0.0021	0.00337	0.00353
13	0.00532	0.00155	0.00113	0.00594	0.00324	0.00458	0.00215	0.00174	0.00117	0.00068	0.00091	0.00049	0.00138	0.00094	0.00049	0.00034	0.00115	0.00027	0.00054	0.00049
14	0.00506	0.00499	0.00107	0.00645	0.00563	0.00339	0.0054	0.00628	0.00597	0.00368	0.00443	0.00337	0.00643	0.00299	0.00237	0.00281	0.00495	0.00243	0.00288	0.00164
15	0.00456	0.00175	0.00135	0.00392	0.00211	0.00165	0.0037	0.0134	0.00193	0.01055	0.01041	0.00513	0.00205	0.00401	0.00451	0.00121	0.00171	0.00668	0.00613	0.00512
16	0.00661	0.00951	0.00347	0.01903	0.00884	0.01389	0.02769	0.02757	0.00916	0.02604	0.02648	0.02693	0.01542	0.03197	0.02388	0.0126	0.02538	0.03748	0.02293	0.02136
17	0.02541	0.03687	0.01692	0.08035	0.03347	0.04828	0.10191	0.13176	0.04181	0.09075	0.11312	0.05214	0.04257	0.02753	0.04427	0.01052	0.02365	0.01565	0.03198	0.01902
18	0.00132	0.00917	0.00384	0.02032	0.0093	0.01253	0.03225	0.03115	0.00948	0.02879	0.03152	0.02608	0.01421	0.02428	0.02837	0.00508	0.01274	0.01538	0.02634	0.02406
19	0.00426	0.00995	0.00394	0.01809	0.00762	0.01218	0.02139	0.03213	0.00667	0.03548	0.0239	0.02667	0.01097	0.01761	0.02575	0.00474	0.00967	0.01361	0.03124	0.0251
20	0.00056	0.0001	2.71E-05	0.00011	5.63E-05	7.38E-05	0.00011	0.0001	5.47E-05	7.84E-05	0.00253	8.05E-05	4.13E-05	0.00215	0.00015	1.16E-05	9.34E-05	9.73E-05	0.00016	0.00017

شکل (۴): تصویری از فایل CSV داده ها در اکسل

۵- کامپایل برنامه نگاشت کاهش نوشته شده در زبان جاوا

- کامپایل فایل جاوا و نمایش خروجی های آن در شکل ۵

```
moses@moses:~/me$ javac -cp $(hadoop classpath) AnalyticsFeatureRanker.java
moses@moses:~/me$ ls -la
total 46180
drwxr-xr-x 2 moses moses 4096 May 29 21:28 .
drwxr-x--- 8 moses moses 4096 May 29 21:26 ..
-rw-rw-r-- 1 moses moses 4140 May 29 21:28 'AnalyticsFeatureRanker$FeatureExtractMapper.class'
-rw-rw-r-- 1 moses moses 5656 May 29 21:28 'AnalyticsFeatureRanker$GainComputeReducer.class'
-rw-rw-r-- 1 moses moses 3845 May 29 21:28 'AnalyticsFeatureRanker$PartialAggregateCombiner.class'
-rw-rw-r-- 1 moses moses 10739 May 29 21:28 AnalyticsFeatureRanker.class
-rw-r--r-- 1 moses moses 17557 May 29 21:23 AnalyticsFeatureRanker.java
```

شکل (۵): خروجی کامپایل برنامه نگاشت کاهش

- استفاده از دستور jar و ساخت jar file اجرایی با استفاده از فایل های class. حاوی bytecode های ماشین مجازی جاوا(JVM)^{۱۱} در شکل ۶ نشان داده شده است.

```
moses@moses:~/me$ jar cf analytics-feature-rank.jar AnalyticsFeatureRanker*.class
moses@moses:~/me$ ls -la
total 46192
drwxr-xr-x 2 moses moses 4096 May 29 21:30 .
drwxr-x--- 8 moses moses 4096 May 29 21:26 ..
-rw-rw-r-- 1 moses moses 4140 May 29 21:28 'AnalyticsFeatureRanker$FeatureExtractMapper.class'
-rw-rw-r-- 1 moses moses 5656 May 29 21:28 'AnalyticsFeatureRanker$GainComputeReducer.class'
-rw-rw-r-- 1 moses moses 3845 May 29 21:28 'AnalyticsFeatureRanker$PartialAggregateCombiner.class'
-rw-rw-r-- 1 moses moses 10739 May 29 21:28 AnalyticsFeatureRanker.class
-rw-r--r-- 1 moses moses 17557 May 29 21:23 AnalyticsFeatureRanker.java
-rw-rw-r-- 1 moses moses 11929 May 29 21:30 analytics-feature-rank.jar
-rw-r--r-- 1 moses moses 47222902 May 29 19:44 normalized_dataset.csv
```

شکل (۶): ایجاد Jar File

- فرآیند نصب و راه اندازی Apache Hadoop و تنظیم آن بعنوان یک Startup Service توسط systemd در پیوست شماره ۱ بیان شده است. در صورتیکه هدوپ در حال اجرا نبود با استفاده از دستورات شکل ۷ می توان متغیرهای محلی آن را تنظیم و تمامی سرویس های هدوپ را اجرا کرد. همچنین با دستور jps در هر لحظه می توان شرایط سرویس ها را بررسی کرد.

```
moses@moses:~/me$ export HADOOP_HOME=/usr/local/hadoop
moses@moses:~/me$ export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin
moses@moses:~/me$ export HADOOP_CLASSPATH=$(hadoop classpath)
moses@moses:~/me$ start-all.sh
WARNING: Attempting to start all Apache Hadoop daemons as moses in 10 seconds.
WARNING: This is not a recommended production deployment configuration.
WARNING: Use CTRL-C to abort.
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [moses]
Starting resourcemanager
Starting nodemanagers
```

شکل (۷): اجرای هدوپ

^{۱۱} Java Virtual Machine

- برای اطمینان از بروز هر نوع مشکل بهتر است تمامی فایل های اجراهای گذشته را پاک کرد برای این کار به مانند دستور استفاده شده در شکل ۸ عمل می کنیم.

```
moses@moses:~/me$ hdfs dfs -rm -r -f /user/moses/input /user/moses/output /user/moses/temp
Deleted /user/moses/input
Deleted /user/moses/output
```

شکل(۸): پاک کردن فایل ها روی HDFS

در ادامه فایل مجموعه داده را در HDFS بارگذاری می کنیم و صحت انتقال آن را بررسی خواهیم نمود.

```
moses@moses:~/me$ hdfs dfs -mkdir /user/moses/input/
moses@moses:~/me$ hdfs dfs -put normalized_dataset.csv /user/moses/input/
moses@moses:~/me$ hdfs dfs -ls -h /user/moses/input/
Found 1 items
-rw-r--r-- 1 moses supergroup 45.0 M 2026-05-29 21:57 /user/moses/input/normalized_dataset.csv
```

- در این مرحله می توان یک اجرای آزمایشی از کار تا به این مرحله گرفت. برای این کار دستور زیر را اجرا می کنیم و در آن پارامترهایی مانند فایل برنامه، کلاس اصلی برنامه، محل فایل مجموعه داده و محل ذخیره خروجی را مشخص می کنیم. شکل ۹ نحو اجرای دستور و بخشی از خروجی آن را نشان می دهد.

```
hadoop jar analytics-feature-rank.jar AnalyticsFeatureRanker
/user/moses/input/normalized_dataset.csv /user/moses/output/feature_scores
```

```
moses@moses:~/me$ hadoop jar analytics-feature-rank.jar AnalyticsFeatureRanker /user/moses/input/normalized_dataset.csv /user/moses/output/feature_scores
Header has 513 columns
Target column at index 512: 'label'
Target column index: 512
=== Dataset Statistics ===
Total records: 5000
Class distribution: 0:2500,1:2500
Unique classes: 2

=== Starting Hadoop Job ===
Input: /user/moses/input/normalized_dataset.csv
Output: /user/moses/output/feature_scores
```

شکل(۹): اجرای دستور پایه هادوپ

اجرای پایه موفقیت آمیز بود عملکرد اجرا در شکل ۱۰ نشان داده شده است:

```
2026-05-29 22:01:40,089 INFO mapreduce.Job: map 0% reduce 0%
2026-05-29 22:02:04,524 INFO mapreduce.Job: map 55% reduce 0%
2026-05-29 22:02:09,932 INFO mapreduce.Job: map 74% reduce 0%
2026-05-29 22:02:13,129 INFO mapreduce.Job: map 100% reduce 0%
2026-05-29 22:02:52,565 INFO mapreduce.Job: map 100% reduce 20%
2026-05-29 22:02:54,618 INFO mapreduce.Job: map 100% reduce 30%
2026-05-29 22:02:56,737 INFO mapreduce.Job: map 100% reduce 40%
2026-05-29 22:03:01,088 INFO mapreduce.Job: map 100% reduce 50%
2026-05-29 22:03:04,289 INFO mapreduce.Job: map 100% reduce 60%
2026-05-29 22:03:22,585 INFO mapreduce.Job: map 100% reduce 70%
2026-05-29 22:03:23,619 INFO mapreduce.Job: map 100% reduce 100%
2026-05-29 22:03:26,817 INFO mapreduce.Job: Job job_1780090870994_0001 completed successfully
```

شکل(۱۰): نمایش روند اجرای توابع نگاشت کاهش

در شکل ۱۱ خروجی نهایی برای محاسبه Information Gain (IG) برای اجرای برنامه پایه نشان داده شده است. نتایج بین ۰ تا ۱ هستند که نشان از محاسبه عادی IG دارد.

```
Job completed successfully!
```

```
=====
```

```
TOP 100 FEATURES BY INFORMATION GAIN
```

```
=====
```

Rank	Feature Name	Score
1	feature_0000	0.985739
2	feature_0255	0.941940
3	feature_0139	0.901130
4	feature_0001	0.888944
5	feature_0232	0.873896
6	feature_0116	0.870527
7	feature_0141	0.866272
8	feature_0004	0.864998
9	feature_0008	0.862652
10	feature_0480	0.861800
11	feature_0069	0.858396
12	feature_0131	0.857992
13	feature_0464	0.855522
14	feature_0002	0.854275
15	feature_0080	0.851526
16	feature_0137	0.851322
17	feature_0400	0.850258
18	feature_0496	0.848144
19	feature_0016	0.847301
20	feature_0133	0.844933

شکل (۱۱): مشاهده مقدار IG برای ۲۰ عدد از ۱۰۰ فیچر برتر

۶- اجرای سناریو با ۱۲ آزمایش

این سناریو با اجرای کدهای قرار داده شده در پیوست ۳ پیاده سازی شده است. در این سناریو الگوریتم Random Forest بعنوان طبقه بند بکاربرده شده است. برای هر آزمایش از ۱۰۰ ویژگی که توسط توسط آزمایش مرحله قبل دارای IG بالاتری بوده اند استفاده شده است. تصویر ۱۲ اجرای آزمایش شماره ۱۲ را نشان می دهد:

```
[EXPERIMENT 12] Starting...
Description: balanced_full
Parameters: Mappers=5, Reducers=5, Chunk Size=1000 KB
Running Hadoop job...
[OK] Job completed in 93.75 seconds
Loading results from HDFS...
Features extracted: 100
Evaluating classifiers on top features...
[RESULT] Best classifier: Random Forest = 0.8866
[RESULT] Execution time: 93.75 seconds
```

شکل (۱۲): خروجی مشخصات اجرایی آزمایش ۱۲

در ادامه نتایج نهایی پیاده سازی سناریو در تصویر ۱۳ نشان داده شده اند.

```
[FINAL] Report saved to: ./experiment_results/FINAL_REPORT.txt
```

=====					
EXPERIMENTS SUMMARY					
=====					
Exp	Status	Time(s)	Features	Best Classifier	Best Acc

1	SUCCESS	114.59	100	Random Forest	0.8894
2	SUCCESS	99.31	100	Random Forest	0.8894
3	SUCCESS	97.05	100	Random Forest	0.8894
4	SUCCESS	98.20	100	Random Forest	0.8894
5	SUCCESS	88.82	100	Random Forest	0.8880
6	SUCCESS	103.06	100	Random Forest	0.8874
7	SUCCESS	83.45	100	Random Forest	0.8872
8	SUCCESS	80.62	100	Random Forest	0.8830
9	SUCCESS	83.58	100	Random Forest	0.8880
10	SUCCESS	92.72	100	Random Forest	0.8864
11	SUCCESS	87.13	100	Random Forest	0.8878
12	SUCCESS	93.75	100	Random Forest	0.8866

Successful experiments: 12/12					

شکل (۱۳): نتایج تحقیق

۷- تحلیل نتایج

به منظور ارزیابی عملکرد سیستم و تأثیر همزمان پارامترهای پیکربندی بر کارایی و دقت، مجموعه‌ای از ۱۲ آزمایش اجرا گردید. در این آزمایش‌ها، متغیرهای مستقل شامل تعداد تسک‌های Map در سه سطح ۱، ۳ و ۵ و تعداد تسک‌های Reduce در سه سطح مشابه و حجم داده ورودی یا Chunk در چهار سطح ۱۰۰، ۲۰۰، ۵۰۰ و ۱۰۰۰ بودند. متغیرهای وابسته نیز شامل زمان اجرا (بر حسب ثانیه) و میزان صحت مدل Random Forest بوده است. هدف از این تحلیل، شناسایی و پیکربندی بهینه از نظر زمان اجرا بدون کاهش معنادار در صحت، و همچنین بررسی رفتار سیستم در مواجهه با افزایش موازی‌سازی و حجم داده است. در ادامه، نتایج در جدول ۳ به تفکیک تأثیر هر یک از این پارامترها و تعاملات بین آنها مورد بحث و تفسیر قرار می‌گیرد.

جدول (۲): تحلیل نتایج

Time	Accuracy	Chunk (Size)	Reduce Task(N)	Map Task(N)	N
۱۱۴.۵۹	۰.۸۸۹۴	۱۰۰	۱	۱	۱
۹۹.۳۱	۰.۸۸۹۴	۲۰۰	۱	۱	۲
۹۷.۰۵	۰.۸۸۹۴	۵۰۰	۱	۱	۳
۹۸.۲۰	۰.۸۸۹۴	۱۰۰۰	۱	۱	۴
۸۸.۸۲	۰.۸۸۸۰	۱۰۰۰	۳	۱	۵
۱۰۳.۰۶	۰.۸۸۷۴	۱۰۰۰	۵	۱	۶
۸۳.۴۵	۰.۸۸۷۲	۱۰۰۰	۱	۳	۷
۸۰.۶۲	۰.۸۸۳۰	۱۰۰۰	۳	۳	۸
۸۳.۵۸	۰.۸۸۸۰	۱۰۰۰	۵	۳	۹
۹۲.۷۲	۰.۸۸۶۴	۱۰۰۰	۱	۵	۱۰
۸۷.۱۳	۰.۸۸۷۸	۱۰۰۰	۳	۵	۱۱
۹۳.۷۵	۰.۸۸۶۶	۱۰۰۰	۵	۵	۱۲

در این مجموعه آزمایش‌ها، سه عامل اصلی به عنوان متغیرهای ورودی (مستقل) در نظر گرفته شده‌اند. نخست، تعداد پردازشگرهای Map که در سه سطح یک، سه و پنج مقداری شده است. دوم، تعداد پردازشگرهای Reduce که همانند Map‌ها در سه سطح یک، سه و پنج تغییر داده شده است. سوم، اندازه Chunk داده یا همان تعداد رکورد ورودی در هر بلوک پردازشی که در چهار سطح صد، دویست، پانصد و هزار تاپل تنظیم گردیده است. ترکیب این سه عامل در مجموع دوازده حالت آزمایشی متفاوت را ایجاد کرده است. لازم به ذکر است که حجم کل داده پردازش شده در آزمایش‌های مختلف یکسان نیست و با تغییر اندازه تکه داده، حجم ورودی نیز تغییر می‌کند.

در مقابل، دو عامل به عنوان متغیرهای خروجی (وابسته) اندازه‌گیری شده‌اند. نخست، مدت زمان اجرای کل فرایند که بر حسب ثانیه ثبت گردیده و نشان‌دهنده کارایی سیستم در هر پیکربندی است. این زمان از لحظه شروع اولین پردازش تا اتمام آخرین Reduce محاسبه شده است. دوم، میزان Accuracy یا صحت نتایج تولید شده که به صورت نسبتی بین صفر و یک بیان می‌شود. این دقت نشان می‌دهد که مدل یادگیری ماشین (که در تمام آزمایش‌ها RM بوده است) تا چه اندازه توانسته رکوردهای آزمایشی را به درستی طبقه‌بندی کند. هدف اصلی تحلیل، بررسی چگونگی تأثیر تغییرات در تعداد پردازشگرهای نقشه و کاهش و همچنین حجم تکه داده، بر روی زمان اجرا و میزان دقت می‌باشد.

۸- نتیجه گیری

بر اساس یافته‌های حاصل از دوازده آزمایش، مشخص گردید که تغییر در تعداد پردازشگرهای Map و Reduce تأثیر مستقیم و معناداری بر مدت زمان اجرا دارد، در حالی که میزان دقت در تمامی پیکربندی‌ها تقریباً ثابت و پایدار باقی می‌ماند. بهترین عملکرد از نظر سرعت، مربوط به پیکربندی با Map Task=3 و Reduce Task=3 همراه با Chunk=1000 بود که زمان اجرای حدود هشتاد ثانیه را به دست داد. به عبارت دیگر، افزایش متوازن و هماهنگ هر دو نوع پردازشگر تا نقطه مشخصی موجب بهبود کارایی می‌شود، اما افزایش بی‌رویه آنها نه تنها سودی ندارد، بلکه به دلیل افزایش سربار مدیریت و ارتباطات، زمان اجرا را افزایش می‌دهد. همچنین مشاهده شد که تأثیر افزایش پردازشگرهای Map بر Reduce زمان اجرا، اندکی بیشتر از تأثیر افزایش پردازشگرهای Reduce است که نشان می‌دهد در این مجموعه داده، مرحله Map گلوگاه اصلی پردازش محسوب می‌شود.

Summarize of Report

In this study, the Apache Hadoop MapReduce parallel processing framework was utilized to compute the Information Gain criterion on large-scale data. The primary objective was to select the 100 most important features from among 2,381 features of the EMBER malware dataset. To achieve this, data comprising 5,000 malware and benign samples were first preprocessed and normalized, then loaded into the Hadoop system. By designing intelligent Mappers capable of locally processing data chunks and Reducers that aggregated the results, the process of calculating the final score for each feature was successfully accomplished.

In the evaluation phase, 12 different experiments were designed and conducted with varying numbers of Mappers, Reducers, and chunk sizes. The results indicate that the best performance in terms of speed is achieved with a balanced configuration of three Mappers, three Reducers, and a chunk size of 1,000 records, which reduced the execution time to approximately 80 seconds. The accuracy of the model remained consistently stable across all configurations, at roughly 88 percent. Furthermore, it was observed that the Map phase constitutes the primary processing bottleneck compared to the Reduce phase. Overall, this research demonstrates that intelligent parallelization can significantly accelerate the processing of large data volumes without compromising accuracy.

٩- منابع

Anderson .H. S. .& Roth .P. (2018). Ember: An open dataset for training static pe malware machine learning models. *arXiv preprint arXiv:1804.04637*.

Dean J. .& Ghemawat .S. (2008). MapReduce: simplified data processing on large clusters. *Communications of the ACM* ٥١ (1) ١١٣-١٠٧ .

Ember Repository. (2022). Add Detailed Information About Ember 2018 Dataset. *Github Commit 4d9b846*.

<https://github.com/mohammad-ahmadzadeh/Bigdata-Apache-hadoop-ex1-InformationGain>